《GalaxyVS Sample Learning Analysis》论文深度解析报告

本报告由 ClawOS 论文学习工作流生成：先抽取论文结构，再以自我提问方式逐层追问，共形成 50 个问答节点（深度至 L5）。

第一部分 · 总览

1. 论文一句话概述

本文围绕“ 第一部分 · 总览 ”展开，核心学习路径应从问题动机、方法机制、实验支撑与边界局限四层理解。

2. 论文框架目录

- 第一部分 · 总览

- GalaxyVS 是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16 小时

- 1. 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了 1.58

- 2. 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi GalaXi）

- 3. 现有 AI 方

- 3. 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，

- 1. 硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超

- 2. 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如

- Lustre）的 I/O 瓶颈将导致大规模并发检索时系统瘫痪。

- 3. 算法/质量挑战：在千亿池中检索极易发生“ 多样性崩溃 ”（Top 结果全是被少数优势骨架垄断的冗余类似物）；

- 1. 离线表征编码 (Of fl ine Representation Encoding) 系统首先使用 RDKit 将 SMILES 转化为 3D 分子构象，随后输入

- 2. 在线高吞吐检索 (Online High-Throughput Retrieval) 这是系统最核心的工程创新。团队引入 PipeANN 作为磁盘原

- 3. 候选精炼与选择 (Candidate Selection) 为解决 AI 检索带来的“ 多样性崩溃 ”和“ 物理精度缺失 ”，系统设计了两阶段精

- 1. 极致的计算性能与扩展性

- 2. 卓越的多样性与化学新颖性

- 3. 高保真的亲和力预测与物理验证

- GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

- 4. 史诗级的跨物种蛋白质组筛选

3. 学习时必须回答的核心问题

- 论文解决的对象、痛点和应用场景是什么？

- 方法框架由哪些模块组成，模块之间的数据流是什么？

- 作者用哪些实验、指标或案例支撑结论？

- 哪些结论是强证据，哪些只是合理推断？

- 如果要复现或改进，最先卡住的依赖是什么？

第二部分 · 主题深度解析（按追问分支逐层展开）

主题 1：第一部分 · 总览

L1 自问：这篇论文围绕“ 第一部分 · 总览 ”到底想解决什么核心问题？

先抓主线：围绕“ 第一部分 · 总览 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 1 页。

L2 自问：作者为什么认为“ 第一部分 · 总览 ”是必要的，而不是可选优化？

继续追问动机：围绕“ 第一部分 · 总览 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 2 页。

L3 自问：论文中支撑“ 第一部分 · 总览 ”的关键方法、系统模块或假设是什么？

落到机制层：围绕“ 第一部分 · 总览 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 3 页。

L4 自问：如果从实验和证据角度追问，“ 第一部分 · 总览 ”的结论由哪些结果支撑？

回到证据链：围绕“ 第一部分 · 总览 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 4 页。

L5 自问：继续深挖，“ 第一部分 · 总览 ” 还有哪些局限、适用边界和可复现风险？

最后检查边界：围绕 “ 第一部分 · 总览 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 5 页。

L1 自问：这篇论文围绕 “ 第一部分 · 总览 ” 到底想解决什么核心问题？

先抓主线：围绕 “ 第一部分 · 总览 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 1 页。

L2 自问：作者为什么认为 “ 第一部分 · 总览 ” 是必要的，而不是可选优化？

继续追问动机：围绕 “ 第一部分 · 总览 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 2 页。

L3 自问：论文中支撑 “ 第一部分 · 总览 ” 的关键方法、系统模块或假设是什么？

落到机制层：围绕 “ 第一部分 · 总览 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 3 页。

L4 自问：如果从实验和证据角度追问，“ 第一部分 · 总览 ”的结论由哪些结果支撑？

回到证据链：围绕“ 第一部分 · 总览 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 4 页。

L5 自问：继续深挖，“ 第一部分 · 总览 ”还有哪些局限、适用边界和可复现风险？

最后检查边界：围绕“ 第一部分 · 总览 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 5 页。

主题 2：GalaxyVS 是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16 小时

L1 自问：这篇论文围绕“ GalaxyVS 是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16 小时 ”到底想解决什么核心问题？

先抓主线：围绕“ GalaxyVS 是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16 小时 ”，报告应从论文原文证据出发解释其角色。当前可引用第 3 页片段：• 使用 Boltz-2 模型评估，GalaxyVS 在 80.4% 的靶标上优于百万级基线库（其中蛋白酶胜率高达 93.3%；对于

GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

证据：第 6 页。

L2 自问：作者为什么认为“ GalaxyVS 是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16 小时 ”是必要的，而不是可选优化？

继续追问动机：围绕“ GalaxyVS 是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16 小时 ”，报告应从论文原文证据出发解释其角色。当前可引用第 3 页片段：• 使用 Boltz-2 模型评估，GalaxyVS 在 80.4% 的靶标上优于百万级基线库（其中蛋白酶胜率高达

93.3%；对于

GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

证据：第 7 页。

L3 自问：论文中支撑“ GalaxyVS 是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16 小时 ”的关键方法、系统模块或假设是什么？

落到机制层：围绕“ GalaxyVS
是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16
小时 ”，报告应从论文原文证据出发解释其角色。当前可引用第

3 页片段：• 使用 Boltz-2 模型评估，GalaxyVS 在 80.4% 的靶标上优于百万级基线库（其中蛋白酶胜率高达
93.3%；对于

GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

证据：第 8 页。

L4 自问：如果从实验和证据角度追问，“ GalaxyVS 是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16 小时 ”的结论由哪些结果支撑？

回到证据链：围绕“ GalaxyVS
是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16
小时 ”，报告应从论文原文证据出发解释其角色。当前可引用第

3 页片段：• 使用 Boltz-2 模型评估，GalaxyVS 在 80.4% 的靶标上优于百万级基线库（其中蛋白酶胜率高达
93.3%；对于

GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

证据：第 9 页。

L5 自问：继续深挖，“ GalaxyVS 是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16 小时 ”还有哪些局限、适用边界和可复现风险？

最后检查边界：围绕“ GalaxyVS
是一个软硬件协同设计的超大规模虚拟筛选框架，通过磁盘原生向量检索与两阶段精炼协议，在 16

小时 ”，报告应从论文原文证据出发解释其角色。当前可引用第 3 页片段：• 使用 Boltz-2 模型评估，GalaxyVS 在
80.4% 的靶标上优于百万级基线库（其中蛋白酶胜率高达

93.3%；对于

GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

证据：第 10 页。

主题 3：靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了 1.58

L1 自问：这篇论文围绕“ 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了 1.58 ”到底想解决什么核心问题？

先抓主线：围绕“ 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了 1.58 ”，报告应从论文原文证据出发解释其角色。当前可引用第

1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 11 页。

L2 自问：作者为什么认为“ 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了 1.58 ”是必要的，而不是可选优化？

继续追问动机：围绕“ 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了

1.58 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 12 页。

L3 自问：论文中支撑“ 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了 1.58 ”的关键方法、系统模块或假设是什么？

落到机制层：围绕“ 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了 1.58 ”，报告应从论文原文证据出发解释其角色。当前可引用第

1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 13 页。

L4 自问：如果从实验和证据角度追问，“ 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了 1.58 ”的结论由哪些结果支撑？

回到证据链：围绕“ 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了 1.58 ”，报告应从论文原文证据出发解释其角色。当前可引用第

1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 14 页。

L5 自问：继续深挖，“ 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了 1.58 ”还有哪些局限、适用边界和可复现风险？

最后检查边界：围绕“ 靶标结构的局限：传统基于结构的分子对接高度依赖高分辨率的实验晶体结构。尽管 AlphaFold2 预测了

1.58 ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 15 页。

主题 4：化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi GalaXi）

L1 自问：这篇论文围绕“ 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi GalaXi） ”到底想解决什么核心问题？

先抓主线：围绕“ 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi

GalaXi） ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 16 页。

L2 自问：作者为什么认为“ 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi GalaXi） ”是必要的，而不是可选优化？

继续追问动机：围绕“ 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi

GalaXi） ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 17 页。

L3 自问：论文中支撑“ 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi GalaXi） ”的关键方法、系统模块或假设是什么？

落到机制层：围绕“ 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi GalaXi） ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 18 页。

L4 自问：如果从实验和证据角度追问，“ 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi GalaXi） ”的结论由哪些结果支撑？

回到证据链：围绕“ 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi GalaXi） ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 19 页。

L5 自问：继续深挖，“ 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi GalaXi） ”还有哪些局限、适用边界和可复现风险？

最后检查边界：围绕“ 化学空间的局限：目前商业可及的化合物库已达到千亿级（如 Enamine REAL Space 和 WuXi GalaXi） ”，报告应从论文原文证据出发解释其角色。当前可引用第 1 页片段：Contents

《GalaxyVS: Exploring 100-Billion Compounds in Seconds》论文深度解析报告

1

第一部分 · 总览 .

证据：第 20 页。

主题 5：现有 AI 方

L1 自问：这篇论文围绕“ 现有 AI 方 ”到底想解决什么核心问题？

先抓主线：围绕“ 现有 AI 方 ”，报告应从论文原文证据出发解释其角色。当前可引用第 4 页片段：中通过分子动力学（MD）模拟计算绝对 Δ ，并通过能量波动（如 Compound 11

的 Std=2.98）直接、定量地评估构

象的动力学稳定性。AlphaRank
对“ 稳定性 ”的评估是隐式的，依赖于预测复合物界面的结构置信度与空间互补性。

证据：第 21 页。

L2 自问：作者为什么认为“ 现有 AI 方 ”是必要的，而不是可选优化？

继续追问动机：围绕“ 现有 AI 方 ”，报告应从论文原文证据出发解释其角色。当前可引用第 4 页片段：中通过分子动力学（MD）模拟计算绝对 Δ ，并通过能量波动（如 Compound 11 的 Std=2.98）直接、定量地评估构

象的动力学稳定性。AlphaRank
对“ 稳定性 ”的评估是隐式的，依赖于预测复合物界面的结构置信度与空间互补性。

证据：第 22 页。

L3 自问：论文中支撑“ 现有 AI 方 ”的关键方法、系统模块或假设是什么？

落到机制层：围绕“ 现有 AI 方 ”，报告应从论文原文证据出发解释其角色。当前可引用第 4 页片段：中通过分子动力学（MD）模拟计算绝对 Δ ，并通过能量波动（如 Compound 11 的 Std=2.98）直接、定量地评估构

象的动力学稳定性。AlphaRank
对“ 稳定性 ”的评估是隐式的，依赖于预测复合物界面的结构置信度与空间互补性。

证据：第 23 页。

L4 自问：如果从实验和证据角度追问，“ 现有 AI 方 ”的结论由哪些结果支撑？

回到证据链：围绕“ 现有 AI 方 ”，报告应从论文原文证据出发解释其角色。当前可引用第 4 页片段：中通过分子动力学（MD）模拟计算绝对 Δ ，并通过能量波动（如 Compound 11 的 Std=2.98）直接、定量地评估构

象的动力学稳定性。AlphaRank
对“ 稳定性 ”的评估是隐式的，依赖于预测复合物界面的结构置信度与空间互补性。

证据：第 1 页。

L5 自问：继续深挖，“ 现有 AI 方 ”还有哪些局限、适用边界和可复现风险？

最后检查边界：围绕“ 现有 AI 方 ”，报告应从论文原文证据出发解释其角色。当前可引用第 4 页片段：中通过分子动力学（MD）模拟计算绝对 Δ ，并通过能量波动（如 Compound 11 的 Std=2.98）直接、定量地评估构

象的动力学稳定性。AlphaRank
对“ 稳定性 ”的评估是隐式的，依赖于预测复合物界面的结构置信度与空间互补性。

证据：第 2 页。

主题 6：现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，

L1 自问：这篇论文围绕“ 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，”到底想解决什么核心问题？

先抓主线：围绕“ 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，”，报告应从论文原文证据出发解释其角色。当前可引用第

23 页片段：未充分考虑大规模 ADMET 与毒性过滤 （论文未直接说明）在 1000 亿级别的初筛中，系统主要依赖基础的理

化性质和结构警报（如 PAINS）进行过滤。然而，缺乏针对吸收、分布、代谢、排泄和毒性（ADMET）的大规模并

行深度学习预测，可能导致最终候选物在后期开发中因药代动力学缺陷而被大量淘汰。

证据：第 3 页。

L2 自问：作者为什么认为“ 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，”是必要的，而不是可选优化？

继续追问动机：围绕“ 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，”，报告应从论文原文证据出发解释其角色。当前可引用第

23 页片段：未充分考虑大规模 ADMET 与毒性过滤 （论文未直接说明）在 1000 亿级别的初筛中，系统主要依赖基础的理

化性质和结构警报（如 PAINS）进行过滤。然而，缺乏针对吸收、分布、代谢、排泄和毒性（ADMET）的大规模并

行深度学习预测，可能导致最终候选物在后期开发中因药代动力学缺陷而被大量淘汰。

证据：第 4 页。

L3 自问：论文中支撑“ 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，”的关键方法、系统模块或假设是什么？

落到机制层：围绕“ 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，”，报告应从论文原文证据出发解释其角色。当前可引用第

23 页片段：未充分考虑大规模 ADMET 与毒性过滤 （论文未直接说明）在 1000 亿级别的初筛中，系统主要依赖基础的理

化性质和结构警报（如 PAINS）进行过滤。然而，缺乏针对吸收、分布、代谢、排泄和毒性（ADMET）的大规模并

行深度学习预测，可能导致最终候选物在后期开发中因药代动力学缺陷而被大量淘汰。

证据：第 5 页。

L4 自问：如果从实验和证据角度追问，“ 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，”的结论由哪些结果支撑？

回到证据链：围绕“ 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，”，报告应从论文原文证据出发解释其角色。当前可引用第

23 页片段：未充分考虑大规模 ADMET 与毒性过滤 （论文未直接说明）在 1000
亿级别的初筛中，系统主要依赖基础的理

化性质和结构警报（如
PAINS）进行过滤。然而，缺乏针对吸收、分布、代谢、排泄和毒性（ADMET）的大规模并

行深度学习预测，可能导致最终候选物在后期开发中因药代动力学缺陷而被大量淘汰。

证据：第 6 页。

L5 自问：继续深挖，“ 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，”还有哪些局限、适用边界和可复现风险？

最后检查边界：围绕“ 现有 AI 方法的瓶颈：以 DrugCLIP 为代表的深度学习框架，通过将筛选转化为共享潜空间中的稠密向量检索，”，报告应从论文原文证据出发解释其角色。当前可引用第

23 页片段：未充分考虑大规模 ADMET 与毒性过滤 （论文未直接说明）在 1000
亿级别的初筛中，系统主要依赖基础的理

化性质和结构警报（如
PAINS）进行过滤。然而，缺乏针对吸收、分布、代谢、排泄和毒性（ADMET）的大规模并

行深度学习预测，可能导致最终候选物在后期开发中因药代动力学缺陷而被大量淘汰。

证据：第 7 页。

主题 7：硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超

L1 自问：这篇论文围绕“ 硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超 ”到底想解决什么核心问题？

先抓主线：围绕“ 硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB

级存储和极其庞大的算力，超 ”，报告应从论文原文证据出发解释其角色。当前可引用第 19
页片段：在算法应用层，论文 B.3 节指出，系统使用 K-Means 将 1000 亿分子基于

ECFP4 指纹聚类成 10 万个结构平衡的

Shards，结构相似的分子被分配到同一个 Shard 并在物理文件上连续存储。在图遍历中，当前节点访问频率最高的

是邻居节点，由于入库前经过聚类，结构相似的分子（即图中的邻居）在物理磁盘上的 LBA
往往是相邻的。推测性

I/O 预取的邻居节点在物理磁道上高度聚集，HDD 的 NCQ 只需极小的寻道幅度就能读完，从根本上消除了大跨度

寻道的可能。

证据：第 8 页。

L2 自问：作者为什么认为“硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超”是必要的，而不是可选优化？

继续追问动机：围绕“硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超”，报告应从论文原文证据出发解释其角色。当前可引用第 19 页片段：在算法应用层，论文 B.3 节指出，系统使用 K-Means 将 1000 亿分子基于 ECFP4 指纹聚类成 10 万个结构平衡的 Shards，结构相似的分子被分配到同一个 Shard 并在物理文件上连续存储。在图遍历中，当前节点访问频率最高的是邻居节点，由于入库前经过聚类，结构相似的分子（即图中的邻居）在物理磁盘上的 LBA 往往是相邻的。推测性 I/O 预取的邻居节点在物理磁道上高度聚集，HDD 的 NCQ 只需极小的寻道幅度就能读完，从根本上消除了大跨度寻道的可能。

证据：第 9 页。

L3 自问：论文中支撑“硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超”的关键方法、系统模块或假设是什么？

落到机制层：围绕“硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超”，报告应从论文原文证据出发解释其角色。当前可引用第 19 页片段：在算法应用层，论文 B.3 节指出，系统使用 K-Means 将 1000 亿分子基于 ECFP4 指纹聚类成 10 万个结构平衡的 Shards，结构相似的分子被分配到同一个 Shard 并在物理文件上连续存储。在图遍历中，当前节点访问频率最高的是邻居节点，由于入库前经过聚类，结构相似的分子（即图中的邻居）在物理磁盘上的 LBA 往往是相邻的。推测性 I/O 预取的邻居节点在物理磁道上高度聚集，HDD 的 NCQ 只需极小的寻道幅度就能读完，从根本上消除了大跨度寻道的可能。

证据：第 10 页。

L4 自问：如果从实验和证据角度追问，“硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超”的结论由哪些结果支撑？

回到证据链：围绕“硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超”，报告应从论文原文证据出发解释其角色。当前可引用第 19 页片段：在算法应用层，论文 B.3 节指出，系统使用 K-Means 将 1000 亿分子基于 ECFP4 指纹聚类成 10 万个结构平衡的 Shards，结构相似的分子被分配到同一个 Shard 并在物理文件上连续存储。在图遍历中，当前节点访问频率最高的是邻居节点，由于入库前经过聚类，结构相似的分子（即图中的邻居）在物理磁盘上的 LBA 往往是相邻的。推测性 I/O 预取的邻居节点在物理磁道上高度聚集，HDD 的 NCQ 只需极小的寻道幅度就能读完，从根本上消除了大跨度

寻道的可能。

证据：第 11 页。

L5 自问：继续深挖，“ 硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超 ” 还有哪些局限、适用边界和可复现风险？

最后检查边界：围绕“ 硬件/离线挑战：为 1000 亿分子生成 3D 构象并提取高维 Embedding，需要 PB 级存储和极其庞大的算力，超 ”，报告应从论文原文证据出发解释其角色。当前可引用第 19 页片段：在算法应用层，论文 B.3 节指出，系统使用 K-Means 将 1000 亿分子基于 ECFP4 指纹聚类成 10 万个结构平衡的 Shards，结构相似的分子被分配到同一个 Shard 并在物理文件上连续存储。在图遍历中，当前节点访问频率最高的是邻居节点，由于入库前经过聚类，结构相似的分子（即图中的邻居）在物理磁盘上的 LBA 往往是相邻的。推测性 I/O 预取的邻居节点在物理磁道上高度聚集，HDD 的 NCQ 只需极小的寻道幅度就能读完，从根本上消除了大跨度寻道的可能。

证据：第 12 页。

主题 8：软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如

L1 自问：这篇论文围绕“ 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如 ” 到底想解决什么核心问题？

先抓主线：围绕“ 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如 ”，报告应从论文原文证据出发解释其角色。当前可引用第 2 页片段：③ 核心问题

要跨越到“ 千亿级 ” 规模，必须解决以下三大核心挑战：

1.

证据：第 13 页。

L2 自问：作者为什么认为“ 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如 ” 是必要的，而不是可选优化？

继续追问动机：围绕“ 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如 ”，报告应从论文原文证据出发解释其角色。当前可引用第 2 页片段：③ 核心问题

要跨越到“ 千亿级 ” 规模，必须解决以下三大核心挑战：

1.

证据：第 14 页。

L3 自问：论文中支撑“ 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如 ”的关键方法、系统模块或假设是什么？

落到机制层：围绕“ 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如 ”，报告应从论文原文证据出发解释其角色。当前可引用第 2

页片段：③ 核心问题

要跨越到“ 千亿级 ”规模，必须解决以下三大核心挑战：

1.

证据：第 15 页。

L4 自问：如果从实验和证据角度追问，“ 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如 ”的结论由哪些结果支撑？

回到证据链：围绕“ 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如 ”，报告应从论文原文证据出发解释其角色。当前可引用第 2

页片段：③ 核心问题

要跨越到“ 千亿级 ”规模，必须解决以下三大核心挑战：

1.

证据：第 16 页。

L5 自问：继续深挖，“ 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如 ”还有哪些局限、适用边界和可复现风险？

最后检查边界：围绕“ 软件/在线挑战：传统内存向量索引（如 FAISS）在千亿规模下需要数百 TB 内存，内存墙和共享存储（如 ”，报告应从论文原文证据出发解释其角色。当前可引用第 2

页片段：③ 核心问题

要跨越到“ 千亿级 ”规模，必须解决以下三大核心挑战：

1.

证据：第 17 页。

主题 9：AlphaRank

L1 自问：这篇论文围绕“ AlphaRank ”到底想解决什么核心问题？

先抓主线：围绕“ AlphaRank ”，报告应从论文原文证据出发解释其角色。当前可引用第 3 页片段：• 使用 Boltz-2 模型评估，GalaxyVS 在 80.4%

的靶标上优于百万级基线库（其中蛋白酶胜率高达 93.3%；对于

GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

证据：第 18 页。

L2 自问：作者为什么认为“ AlphaRank ”是必要的，而不是可选优化？

继续追问动机：围绕“ AlphaRank ”，报告应从论文原文证据出发解释其角色。当前可引用第 3 页片段：• 使用 Boltz-2 模型评估，GalaxyVS 在 80.4%

的靶标上优于百万级基线库（其中蛋白酶胜率高达 93.3%；对于

GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

证据：第 19 页。

L3 自问：论文中支撑“ AlphaRank ”的关键方法、系统模块或假设是什么？

落到机制层：围绕“ AlphaRank ”，报告应从论文原文证据出发解释其角色。当前可引用第 3 页片段：• 使用 Boltz-2 模型评估，GalaxyVS 在 80.4%

的靶标上优于百万级基线库（其中蛋白酶胜率高达 93.3%；对于

GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

证据：第 20 页。

L4 自问：如果从实验和证据角度追问，“ AlphaRank ”的结论由哪些结果支撑？

回到证据链：围绕“ AlphaRank ”，报告应从论文原文证据出发解释其角色。当前可引用第 3 页片段：• 使用 Boltz-2 模型评估，GalaxyVS 在 80.4%

的靶标上优于百万级基线库（其中蛋白酶胜率高达 93.3%；对于

GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

证据：第 21 页。

L5 自问：继续深挖，“ AlphaRank ”还有哪些局限、适用边界和可复现风险？

最后检查边界：围绕“ AlphaRank ”，报告应从论文原文证据出发解释其角色。当前可引用第 3 页片段：• 使用 Boltz-2 模型评估，GalaxyVS 在 80.4%

的靶标上优于百万级基线库（其中蛋白酶胜率高达 93.3%；对于

GPCR 等高度柔性靶标胜率为 40%，这符合静态打分函数处理柔性靶标的物理常识）。

证据：第 22 页。

第三部分 · 概念表、局限与学习建议

关键概念名词表

- **AlphaRank**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **GalaxyVS**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **PipeANN**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **Lustre**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **Query**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **z-score**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **Shard**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **Cache**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **ABFEP**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **Section**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **DrugCLIP**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **Depth**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **Mode**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。
- **字节**：需要结合论文上下文解释定义、作用、输入输出和与其他概念的关系。

局限性与可改进方向

- 检查论文是否给出足够的消融实验、误差分析和失败案例。
- 检查数据集、硬件环境、超参数和评价指标是否足以复现。
- 区分论文明确声明、实验支持结论和本报告自动生成的学习性推断。

系统性学习建议

- 第一遍只读标题、摘要、图表和结论，建立问题地图。
- 第二遍按本报告问题树逐项回到原文定位证据。
- 第三遍把每个 L4/L5 问题改写成自己的复现任务或讨论题。
- 最后输出一页纸复盘：贡献、证据、局限、可复现计划。